



UNIVERSIDAD TORCUATO DI TELLA

-Departamento de Economía-
Maestría en Econometría

Trabajo final módulo R

Autor:

Lucía Calderón Sosinowicz

Profesor:

Ian Bounos

Índice General

1. Elección del dataset y la técnica	2
2. Análisis exploratorio de datos	3
2.1. Cantidad de horas trabajadas semanalmente	3
2.2. Edad y edad al cuadrado	5
2.3. Sexo	7
2.4. Presencia de menores de 6 años en el hogar	7
2.5. Nivel educativo	8
2.6. Rama de actividad del negocio	9
2.7. Ocupación del trabajador	11
2.8. Percepción de ingresos no laborales	12
3. Aplicación de la técnica e interpretación	14
3.1. Mínimos cuadrados clásicos	14
3.1.1. Diagnóstico del modelo	16
3.2. Modelos con regularización: Ridge y Lasso	16
4. Segunda parte	17
5. Conclusiones	22

1. Elección del dataset y la técnica

Para abordar esta investigación, la pregunta central que guió el análisis fue: ¿De qué manera los factores sociodemográficos y las características del puesto de trabajo determinan la cantidad de horas trabajadas por los asalariados en Argentina, y cuáles de estas variables emergen como los predictores más relevantes bajo un esquema de selección por regularización?

Para dar respuesta a este planteo se eligió como fuente de información la Encuesta Permanente de Hogares (EPH) elaborada por el INDEC. Esta base de datos es adecuada para responder la pregunta de investigación dado que permite capturar con gran nivel de profundidad tanto las características sociodemográficas individuales como las del hogar. Además, al tratarse de un relevamiento oficial sobre la población y el mercado laboral argentino garantiza una muestra sólida y estandarizada para evaluar cuantitativamente los determinantes de la oferta laboral asalariada.

De esta manera, se utilizaron los datos de la EPH del primer trimestre de 2026, los datos más actuales que pueden descargarse utilizando el paquete EPH en R. La base cuenta con 43.739 observaciones de 234 variables por lo que su amplitud ofrece el volumen y la heterogeneidad de observaciones necesarios para aplicar técnicas econométricas tales como la estimación por mínimos cuadrados clásicos, y los métodos de regularización Ridge y Lasso. Puntualmente, al observar la base en profundidad se eligió como variable dependiente el total de horas trabajadas en la semana en la ocupación principal por el asalariado (código PP3E.TOT) y como independientes:

1. la edad (código CH06). Se esperaría un coeficiente estimado positivo para esta variable, dado que la cantidad de horas trabajadas suele aumentar a medida que las personas consolidan sus carreras y adquieren experiencia;
2. la edad al cuadrado, que se construyó y agregó a la base de datos "limpia", para la cual se esperaría un coeficiente negativo que capture el hecho de que al acercarse a la edad de jubilación, la oferta laboral tiende a descender debido a la preferencia por el tiempo libre;
3. el sexo (código CH04), del cual se esperaría un coeficiente negativo para las mujeres en comparación con los varones.
4. la presencia de menores de 6 años en el hogar. Esta variable se construyó agrupando a los individuos según el código del hogar (CODOSU) y filtrando si al menos uno de los integrantes era menor de 6 años. Se esperaría un impacto negativo sobre la cantidad de horas trabajadas en el mercado laboral independientemente del sexo del individuo;
5. el nivel educativo (código NIVEL_ED). Para esta variable se combinan dos efectos: el de sustitución indica que a mayor nivel educativo mayor es el salario, por lo que se 'encarece' el tiempo libre lo que lleva a trabajar más horas; y el de 'riqueza' por el cual un mayor ingreso lleva a valorar más el tiempo libre, reduciendo las horas de trabajo. El signo del coeficiente estimado depende de cuál de estos efectos predomine sobre el otro;
6. la rama de actividad del negocio/empresa/institución (código caes_seccion_code). Esta variable se recodificó utilizando la función `organize_caes` del paquete EPH, que permitió agrupar las ramas de actividad según el manual de Clasificación de Actividades Económicas para Encuestas Sociodemográficas del MERCOSUR. De esta manera, las ramas de actividad se agruparon en 22 grandes categorías identificadas con letras;
7. la ocupación del trabajador. Nuevamente, esta variable fue recodificada basándose en el Clasificador Nacional de Ocupaciones (INDEC-2001) separando el primer dígito del código que indentifica a cada ocupación. Este dígito identifica a las ocupaciones en 9 grandes grupos;
8. y la percepción de ingresos no laborales por parte del asalariado. Se esperaría que al disponer de recursos independientes del salario, el individuo pueda permitirse 'comprar' más ocio o reducir la exposición a jornadas laborales largas.

9. Por otra parte parte, además de las variables regresoras se agregó a la base 'limpia' la variable expansión (PONDERA) para garantizar que los resultados reflejen fielmente a la población y corregir posibles sesgos de muestreo.

Todo el proceso de creación, modificación, selección y filtrado de variables se realizó de manera iterativa en distintos momentos del trabajo. Pero, lo principal es destacar que primero se filtró a los ocupados (empleados y obreros, categoría 3 de la variable CAT_OCUP) con estado activo (categoría 1 de la variable ESTADO).

Se decidió excluir del análisis a aquellos individuos que, aun siendo clasificados formalmente como asalariados y ocupados, reportaron cero horas trabajadas en su ocupación principal ($PP3E_TOT == 0$). Esto se debe a que el objetivo del modelo fue explicar la intensidad de la jornada laboral de los trabajadores en activo durante el período de referencia, apartando a quienes se encontraban bajo licencias extraordinarias, suspensiones o inactividades transitorias que distorsionaban la relación teórica entre las características sociodemográficas y la oferta laboral efectiva.

Finalmente, para terminar la etapa de selección del dataset se eliminaron los valores NA de la base.

Para abordar empíricamente la pregunta de investigación se eligieron las técnicas vistas en la clase 2, combinando la estimación tradicional por MCO con métodos de selección por regularización. Esta combinación permitió un análisis complementario ya que MCO actúa como el punto de referencia teórico y estadístico inicial y los métodos de regularización permiten manejar la gran dimensión de variables explicativas y la posible multicolinealidad, seleccionando las mejores predictoras de manera eficiente.

2. Análisis exploratorio de datos

2.1. Cantidad de horas trabajadas semanalmente

- Tipo de variable: numérica discreta.


En primer lugar, para analizar a la variable dependiente se ejecutó la función summary en R. Lo llamativo en este caso fue que el valor máximo de la variable era 999. Sin embargo, al revisar el Diseño de registros y estructura para las bases preliminares Hogar y Personas que proporciona el INDEC se encontró que los códigos 9, 99, 999, 9999 corresponden a la categoría de respuesta No sabe/No contesta, por lo que se trataba de datos faltantes. Al contarlos se encontró que eran 20 individuos, por lo que la decisión fue eliminarlos de la base.

Además, para agregar al filtrado de datos se eliminaron a aquellas personas que declararon haber trabajado más de 80 horas semanales por considerarse valores atípicos inviables desde el punto de vista físico-temporal para una relación laboral en relación de dependencia, evitando sesgos severos en los estimadores de MCO. Por el contrario, se decidió no aplicar ningún filtro inferior en las horas trabajadas (cuyo valor mínimo observado es de 1 hora semanal). Mantener los valores bajos permitió capturar fielmente la realidad del mercado de trabajo (caracterizado por la presencia de empleo a tiempo parcial, subocupación y ocupaciones marginales u ocasionales), preservando la representatividad de la muestra.

Luego, se graficaron el diagrama de caja y bigotes y el histograma correspondiente, con el objetivo de evaluar la distribución de la variable.

Detección de Valores Extremos en Horas Trabajadas


Ocupación principal (Población asalariada ponderada)



(a) Boxplot

Distribución de Horas Semanales Trabajadas

Agrupado en intervalos de 5 horas



(b) Histograma

Figura 1: Distribución de la cantidad de horas trabajadas

La distribución de la cantidad de horas trabajadas por semana presenta una marcada concentración en torno a la jornada laboral estándar. El histograma muestra un pico muy pronunciado que se ubica exactamente en la categoría de entre 35 y 40 horas semanales, concentrando el mayor volumen de la población. Este comportamiento central se corrobora de forma simétrica en el boxplot, donde la línea de la mediana se posiciona en ese mismo valor de 40 horas, indicando que el 50 % de los trabajadores se encuentra por debajo y el otro 50 % por encima de dicho umbral.

En cuanto a la dispersión y la forma general de la distribución, el rango intercuartílico del boxplot delimita que el 50 % central de las observaciones se concentra aproximadamente entre las 25 y las 45 horas semanales. Esta variabilidad se visualiza en el histograma, el cual muestra una importante densidad de frecuencias en los rangos de 20 a 30 horas, lo que da cuenta de la marcada presencia de empleos a tiempo parcial, ocupaciones de menor intensidad horaria o situaciones de subocupación. Finalmente, la distribución exhibe una asimetría hacia la derecha conformada por una cola superior extendida. El boxplot señala la presencia de diversos valores extremos representados como puntos individuales que se desplazan desde las 60 hasta el límite superior de las 80 horas semanales. Esto se observa en el histograma en las barras de menor frecuencia ubicadas en los intervalos de la derecha; si bien estadísticamente califican como outliers según la regla del rango intercuartílico, representan situaciones laborales reales y viables (como jornadas prolongadas, horas extra) que justifican su conservación en el análisis.

2.2. Edad y edad al cuadrado

- Tipos de variables: numéricas discretas.


En primer lugar, se filtraron de la base de datos a las personas menores de 18 años y mayores de 65. Por un lado, el límite inferior de 18 años marca la mayoría de edad legal y la finalización del ciclo de educación obligatoria, excluyendo a los menores de edad. Por otro lado, el límite superior de 65 años se corresponde con la edad legal estándar de jubilación en el sistema previsional argentino, edad a partir de la cual la participación en el mercado de trabajo se reduce drásticamente o responde a dinámicas de retiro muy particulares que alterarían el comportamiento general de la oferta laboral.

Luego, se analizó la distribución de la variable. A partir del diagrama de caja, se observa que la mediana de la edad se sitúa en torno a los 38 años, mientras que el rango intercuartílico exhibe que el núcleo central de la población se concentra entre los 29 y los 48 años. Por su parte, el histograma complementa esta lectura al mostrar la distribución de la masa de trabajadores.

En ese caso se observa una alta concentración en el tramo comprendido entre los 25 y los 45 años, registrando un punto máximo que supera el millón de individuos ponderados en el intervalo de los 35 a los 40 años. Hacia los límites del rango etario considerado, la densidad de población descende progresivamente, reflejando tanto las etapas de inserción laboral temprana en los extremos más jóvenes como la progresiva reducción de la actividad hacia el límite superior de los 65 años.


El análisis de correlación bivariada ponderada permitió observar una asociación estadística significativa entre la edad y la cantidad de horas trabajadas semanalmente por los asalariados. En primer lugar, la correlación entre la edad y las horas trabajadas arrojó un coeficiente de $-0,038$ ($p < 0,001$), lo que denota una relación inversa leve pero sistemática a nivel poblacional: a medida que avanza la edad de los individuos, el promedio de horas trabajadas tiende a disminuir. Por otro lado, al evaluar la relación utilizando la edad al cuadrado, el coeficiente de correlación ascendió a $-0,048$ ($p < 0,001$). Esto reforzó la hipótesis teórica del ciclo de vida, sugiriendo que el efecto de la edad sobre la oferta laboral no es estrictamente lineal, sino que presenta una curvatura o un impacto más fuerte en los extremos del rango etario.

Diagrama de Caja: Distribución de la Edad
Población ponderada (18 a 65 años)



(a) Boxplot

Distribución Etaria de la Población Analizada
Población ponderada (18 a 65 años)



(b) Histograma

Figura 2: Distribución de la cantidad de horas trabajadas

2.3. Sexo

- Tipo de variable: categórica.

Al tratarse el sexo de una variable binaria se creó una nueva variable asignando al valor 1 la categoría 'Varón' y al 0 la categoría 'Mujer'. Al utilizar la función summary se observó que en la muestra habían 5608 mujeres y 6571 varones, con una distribución en la población ponderada como se visualiza en el gráfico a continuación.




Figura 3: Distribución por sexo de la población ponderada

2.4. Presencia de menores de 6 años en el hogar

- Tipo de variable: categórica.

Nuevamente, al utilizar la función summary se observó que en la muestra 10053 individuos no convivían en sus hogares con menores de 6 años mientras que 1907 sí lo hacían, con una distribución en la población ponderada como se observa a continuación.




Figura 4: Distribución por presencia de menores de 6 años en el hogar de la población ponderada

2.5. Nivel educativo

- Tipo de variable: categórica.

Al utilizar la función summary sobre esta variable se observó que el valor mínimo era 1 y el máximo 7, por lo que no había presencia de observaciones con la categoría 9 correspondiente a la respuesta 'No sabe/no contesta'.

En función de la información brindada por el INDEC las categorías se corresponden a:

Tabla 1: Categorías correspondientes a la variable nivel educativo

Categoría	
1	Primario incompleto
2	Primario completo
3	Secundario incompleto
4	Secundario completo
5	Superior y universitario incompleto
6	Superior y universitario completo
7	Sin instrucción

Así, puede observarse la distribución de la población en cada uno de los niveles educativos. Puntualmente predominan, con gran diferencia, los individuos con secundario completo seguidos de los que tienen educación superior y universitaria completa.




Figura 5: Distribución por nivel educativo de la población ponderada

2.6. Rama de actividad del negocio

- Tipo de variable: categórica.

Para evitar una excesiva dimensionalidad y problemas de estimación en los modelos, se evaluó la representatividad de las distintas categorías de esta variable, que cuenta con 22 ramas de actividad distintas. Dado que la inclusión masiva de variables dummy puede incrementar la multicolinealidad, reducir los grados de libertad y afectar la estabilidad de los coeficientes, aquellas categorías cuya participación en el total presentaba porcentajes marginales fueron agrupadas en una única categoría llamada 'Otras ramas'.

Esta simplificación permitió preservar la información estructural relevante del mercado laboral sin perjudicar la eficiencia estadística ni la capacidad predictiva de los modelos de MCO y de regularización. A continuación, se identifica a cada una de ellas en función del manual de Clasificación de Actividades Económicas del MERCOSUR:

Tabla 2: Categorías correspondientes a la variable rama de actividad

Código	Descripción de la Rama de Actividad
C	Industria Manufacturera
F	Construcción
G	Comercio al por mayor y al por menor; reparación de vehículos automotores y motocicletas
H	Transporte y almacenamiento
I	Alojamiento y servicios de comida
N	Actividades administrativas y servicios de apoyo
O	Administración pública y defensa; planes de seguro social obligatorio
P	Enseñanza
Q	Salud humana y servicios sociales
T	Actividades de los hogares como empleadores de personal doméstico
Otras ramas	Agrupamiento de ramas de baja representación muestral

De esta manera, el gráfico de barras muestra que las categorías que comprenden a la mayor cantidad de población son Comercio al por mayor y al por menor; reparación de vehículos automotores y motocicletas, seguido de la categoría agrupada de 'Otras ramas', Administración pública y defensa; planes de seguro social obligatorio y la Industria Manufacturera.




Figura 6: Distribución según rama de actividad de la población ponderada

2.7. Ocupación del trabajador

- Tipo de variable: categórica.

Nuevamente, al tratarse de una variable categórica el summary mostró la cantidad de individuos contenidos en cada categoría, información que se usó para calcular los porcentajes correspondientes a cada una respecto de la población total ponderada.

A continuación se detallan los nombres de las ocupaciones de cada categoría y el porcentaje que representan respecto del total:

Tabla 3: Categorías correspondientes a la variable ocupación del trabajador

Código	Descripción de la Ocupación
0	Ocupaciones de dirección
1	Ocupaciones de gestión administrativa, de planificación y control de gestión, jurídico-legal
2	Ocupaciones de gestión presupuestaria, contable y financiera
3	Ocupaciones de comercialización, transporte, almacenaje y telecomunicaciones
4	Ocupaciones de servicios sociales básicos
5	Ocupaciones de servicios varios
6	Ocupaciones agrícolas, ganaderas, forestales, de la caza y de la pesca
7	Ocupaciones de la producción extractiva, energética, de construcción e infraestructura
8	Ocupaciones de la producción industrial, artesanal y de reparación de bienes de consumo
9	Ocupaciones auxiliares de la producción de bienes y de la prestación de servicios




Figura 7: Distribución por ocupación de la población ponderada

Las categorías que se destacan en mayor medida son: Ocupaciones de comercialización, transporte, almacenaje y telecomunicaciones; y Ocupaciones de servicios varios (arte, deportes, servicios de recreación, gastronómicos, etc).

2.8. Percepción de ingresos no laborales

El summary mostró un valor mínimo de -9, que para esta variable se corresponde a la respuesta 'No sabe/ no responde'. Los 238 individuos pertenecientes a esta categoría fueron eliminados de la base de datos.




Figura 8: Distribución por ingresos no laborales de la población ponderada

El histograma mostró que prácticamente todos los individuos en la EPH no perciben ingresos no laborales. Mantener esta variable en formato continuo habría comprometido las propiedades de los estimadores de MCO. La extrema concentración en cero genera una asimetría muy pronunciada y problemas de heterocedasticidad, donde unos pocos valores positivos aislados habrían ejercido un peso desproporcionado en la estimación, distorsionando los coeficientes globales del modelo.

Ante este escenario, se optó por transformar la variable en un indicador binario (1 si percibe ingresos no laborales, 0 en caso contrario). Esta recodificación permitió capturar de manera limpia el efecto de recibir un ingreso extra en comparación con no hacerlo, garantizando robustez estadística y una correcta interpretación económica de los parámetros estimados.

De esta forma, se observa la proporción de individuos en cada una de las categorías.




Figura 9: Distribución por ingresos no laborales de la población ponderada

Finalmente, luego del EDA y de todo el proceso de filtrado y recodificación de variables la base de datos quedó con 11.960 observaciones. Esta cantidad es suficiente para aplicar las técnicas mencionadas previamente y obtener resultados robustos.

3. Aplicación de la técnica e interpretación

3.1. Mínimos cuadrados clásicos

La primera técnica que se aplicó sobre los datos fue la estimación por mínimos cuadrados clásicos. El modelo que se estimó fue el siguiente:

$$\begin{aligned} \text{Horas}_i = & \beta_0 + \beta_1 \text{Edad}_i + \beta_2 \text{Edad}_i^2 + \beta_3 \text{Varón}_i + \beta_4 \text{Edu}_i + \beta_5 \text{Menores}_i \\ & + \beta_6 \text{IngNoLab}_i + \sum_{j=1}^k \gamma_j \text{Ocup}_{ji} + \sum_{m=1}^l \delta_m \text{Rama}_{mi} + \varepsilon_i \end{aligned} \quad (1)$$

Obteniendo los siguientes resultados

Tabla 4: Resultados de la Regresión MCO

Variables	Estimación	Error Est.	P-valor
(Intercept)	29.70	2.02	$< 2,00 \times 10^{-16}$ ***
edad	0.63	0.07	$< 2,00 \times 10^{-16}$ ***
edad_cuadrado	-0.01	0.00	$< 2,00 \times 10^{-16}$ ***
sexo_labelVarón	4.28	0.28	$< 2,00 \times 10^{-16}$ ***
nivel_ed2	-0.74	0.89	0.407
nivel_ed3	-2.79	0.87	0.001 ***
nivel_ed4	-1.55	0.85	0.068 .
nivel_ed5	-3.93	0.88	$7,97 \times 10^{-6}$ ***
nivel_ed6	-2.94	0.87	0.001 ***
nivel_ed7	-1.93	2.64	0.466
menores_6TRUE	0.57	0.30	0.055 .
ocupacion_trabajador1	-2.68	1.23	0.029 *
ocupacion_trabajador2	-1.48	1.28	0.248
ocupacion_trabajador3	-1.68	1.24	0.174
ocupacion_trabajador4	0.27	1.22	0.823
ocupacion_trabajador5	-5.41	1.25	$1,57 \times 10^{-5}$ ***
ocupacion_trabajador6	-1.29	2.37	0.584
ocupacion_trabajador7	-1.95	1.36	0.153
ocupacion_trabajador8	-1.78	1.24	0.152
ocupacion_trabajador9	-2.93	1.58	0.063 .
rama_agrupadaF	-3.36	0.83	$5,61 \times 10^{-5}$ ***
rama_agrupadaG	0.66	0.52	0.206
rama_agrupadaH	1.26	0.64	0.049 *
rama_agrupadaI	2.23	0.67	0.001 ***
rama_agrupadaN	1.39	0.67	0.036 *
rama_agrupadaO	-3.66	0.58	$2,16 \times 10^{-10}$ ***
rama_agrupadaOtras ramas	-2.43	0.50	$1,26 \times 10^{-6}$ ***
rama_agrupadaP	-14.39	0.71	$< 2,00 \times 10^{-16}$ ***
rama_agrupadaQ	-2.70	0.66	$4,15 \times 10^{-5}$ ***
rama_agrupadaT	-13.82	0.69	$< 2,00 \times 10^{-16}$ ***
ingresos_no_lab_binSí percibe	-3.30	0.36	$< 2,00 \times 10^{-16}$ ***

Nota: R^2 ajustado = 0.25; Estadístico F = 134.2 ($p < 2,2 \times 10^{-16}$); $N = 11,960$.

Códigos de significancia: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

En primer lugar, el modelo arroja un R cuadrado ajustado de 0.25, lo cual indica que el 25 % de la variabilidad de las horas trabajadas es explicado por las variables incluidas. Además, el estadístico F

de significatividad conjunta tiene un valor de prácticamente 0. Esto permite rechazar la hipótesis nula de nulidad conjunta, confirmando que el conjunto de variables explicativas posee un poder predictivo y explicativo altamente significativo sobre la cantidad de horas trabajadas.

Por otra parte, individualmente puede decirse que:

1. La variable edad y su término cuadrático resultaron altamente significativos ($p < 2,0 \times 10^{-16}$). Esto confirma empíricamente la forma de U invertida del perfil laboral a lo largo de la vida: las horas trabajadas aumentan durante la juventud, alcanzan un punto de inflexión y luego descienden hacia la vejez;
2. El coeficiente asociado al varón es positivo, de 4,29 horas semanales y estadísticamente robusto. Controlando por el resto de las variables, los varones destinan en promedio más tiempo al mercado laboral, reflejando las asimetrías de género históricas en la intensidad de la inserción laboral;
3. En cuanto al nivel educativo se observa un patrón general negativo en todas las categorías superiores respecto a la base. Esto confirma la predominancia del efecto renta sobre el efecto sustitución: las personas con mayores niveles educativos suelen acceder a mejores salarios por hora o a trabajos formales donde la productividad marginal del salario permite alcanzar el ingreso deseado con un menor volumen de horas;
4. En cuanto a la estructura del hogar, la presencia de niños menores de 6 años muestra un coeficiente positivo que resulta marginalmente significativo al nivel del 10 %. Si bien la teoría económica suele vincular la existencia de niños a cargo con restricciones en el tiempo disponible para el mercado laboral, el signo positivo observado puede reflejar un predominio del efecto presión de ingresos: dados los costos de mantenimiento que enfrentan los hogares con niños pequeños, los individuos deben intensificar su inserción en el mercado de trabajo para sostener los ingresos familiares.
5. Respecto a la ocupación del trabajador, los resultados evidencian una marcada heterogeneidad en el impacto sobre la oferta horaria según la categoría de empleo. Si bien la mayoría de los grupos ocupacionales no presentan diferencias estadísticamente significativas frente a la categoría base, se destacan algunas excepciones (categorías 5, 1 y 9). Esto sugiere que las diferencias en las horas trabajadas no responden de forma homogénea a cualquier tipo de puesto, sino que responden a dinámicas sectoriales particulares;
6. El resultado para la variable de ingresos no laborales es totalmente robusto y con el signo esperado por la teoría económica. Percibir ingresos no laborales reduce la oferta horaria en más de 3 horas semanales, evidenciando un claro efecto riqueza sobre el tiempo de ocio;
7. La inmensa mayoría de las ramas de actividad presentan coeficientes con un nivel de significatividad estadística sumamente alto, lo que evidencia que el sector económico en el que se desempeña el individuo es un determinante clave de la oferta horaria. Con la excepción de algunas ramas específicas, pertenecer a los distintos sectores productivos introduce desvíos muy marcados en el régimen de trabajo semanal.

3.1.1. Diagnóstico del modelo




Figura 10: Gráficos de diagnóstico del modelo estimado por mínimos cuadrados clásicos

Del análisis de los gráficos de diagnóstico de los residuos del modelo MCO se desprende que, si bien los errores no satisfacen estrictamente el supuesto de normalidad debido a las colas pesadas en la distribución, el Teorema Central del Límite garantiza la validez asintótica de la inferencia. Asimismo, se verificó la ausencia de valores extremos con alta influencia (distancia de Cook dentro de los márgenes aceptables) y se observó gráficamente la presencia de heterocedasticidad (confirmada con el test de Breusch-Pagan, que arrojó un valor P de prácticamente 0). Esto conduciría, en otras circunstancias, a la estimación con errores estándar robustos.

Por otra parte, se evaluó la presencia de multicolinealidad mediante el cálculo de los Factores de Inflación de Varianza. Con la única excepción derivada de la inclusión simultánea de la edad y su término cuadrático, el resto de las variables presentan indicadores ajustados muy inferiores a los umbrales críticos, descartando problemas severos de multicolinealidad en el modelo.

3.2. Modelos con regularización: Ridge y Lasso

Dado que uno de los objetivos centrales de esta investigación fue identificar cuáles son los predictores más relevantes y robustos para modelar las horas trabajadas, la estrategia empírica no se limitó a la estimación por MCO, sino que se complementó mediante la implementación de técnicas de regularización: Ridge y Lasso.

Para evitar el overfitting y evaluar de forma rigurosa la capacidad de generalización fuera de muestra, el conjunto de datos total se particionó de manera aleatoria en un conjunto de entrenamiento (80%) y un conjunto de prueba (20%), fijando una semilla para garantizar la total reproducibilidad de los resultados. Posteriormente, utilizando las matrices de diseño correspondientes a la especificación base del modelo, se implementaron ambos estimadores penalizados. El parámetro de penalización (λ) se determinó mediante validación cruzada de 10 particiones, seleccionando aquel valor que minimiza el error cuadrático medio fuera de muestra.

Al evaluar el desempeño predictivo fuera de muestra mediante el Error Cuadrático Medio (MSE) en el conjunto de prueba, se observó que el modelo OLS alcanza el mejor ajuste predictivo global ($MSE =$

146,38), superando ligeramente al modelo Lasso (146,60) y a Ridge (147,85). Este resultado evidenció que la propiedad de selección de características de Lasso —al anular aquellas categorías ocupacionales de menor relevancia predictiva (categorías 7 y 9, Ocupaciones de la producción extractiva, energética, de construcción e infraestructura, y Ocupaciones auxiliares de la producción de bienes y de la prestación de servicios respectivamente)— logra reducir la varianza del modelo sin incurrir en un sesgo perjudicial, optimizando la capacidad de generalización con datos no observados.

No obstante, dado que se trabajó con un conjunto reducido de variables explicativas, las diferencias en el MSE entre los tres modelos son prácticamente nulas. Esto mismo se corrobora en el gráfico de valores observados frente a los predichos: al comparar los paneles, las nubes de puntos de MCO, Ridge y Lasso exhiben un comportamiento visual sumamente similar, reflejando que la estructura de ajuste global se mantiene prácticamente invariable ante la penalización.




Figura 11

4. Segunda parte

Para la segunda parte del trabajo, se llevó a cabo exactamente el mismo procedimiento metodológico con el fin de comprobar si los resultados observados se mantenían o si sufrían modificaciones frente a cambios en las condiciones del análisis, particularmente, al incluir nuevas variables e interacciones al modelo original. A priori se esperaría que la estimación por el modelo MCO tradicional presentase una menor eficiencia predictiva debido a la incorporación de una gran cantidad de variables explicativas y categorías discretas, lo que eleva notablemente la dimensionalidad de la matriz de diseño. Bajo este escenario, los métodos de regularización como Ridge y Lasso se plantean teóricamente como mejores alternativas, ya que al introducir una penalización sobre los coeficientes logran mitigar el sobreajuste y reducir la varianza general del modelo frente al enfoque clásico.

Para comenzar, a la base de datos original se le agregaron tres variables nuevas.

- El estado civil (código CH07): se trata de una variable categórica que presenta 5 categorías en total (1-unido; 2-casado; 3-separado/divorciado; 4-viudo; 5-soltero).

- La asistencia a un establecimiento educativo (código CH10). Originalmente, en la encuesta de la EPH dicha variable contiene 3 categorías (asiste actualmente a un establecimiento, no asiste pero asistió, o nunca asistió). Sin embargo, el objetivo en esta parte era verificar si asistir o no a un establecimiento educativo influye sobre la cantidad de horas trabajadas, por lo que, luego de corroborar que no habían datos faltantes, se recodificó la variable para obtener 2 categorías: 1) Asiste a un establecimiento; 2) No asiste.
- Por último, se agregó la variable AGLOMERADO, variable categórica que determina el lugar desde donde se realizó la encuesta de la EPH a la persona que fue entrevistada.

A continuación pueden verse los porcentajes que representan las categorías de cada variable en la población ponderada:




Figura 12: Distribución de la población ponderada según estado civil





Figura 13

Luego, se volvieron a repetir los análisis realizados con las técnicas utilizadas previamente: estimación con OLS, Ridge y Lasso.

Al incorporar una mayor dimensionalidad en la especificación econométrica (las 3 nuevas variables, la antigua variable Rama de Actividad con sus 22 categorías desagregadas y tres términos de interacción: edad con sexo, menores de 6 con sexo y nivel educativo y edad), se apreciaron cambios tanto en la magnitud como en la significancia de los coeficientes respecto al modelo OLS base. Este salto metodológico permite observar los siguientes comportamientos:

- Efectos de la edad y transformación no lineal: Mientras que en el modelo base la edad y su término cuadrático presentaban coeficientes directos estables (0,63 y $-0,01$, respectivamente), en la especificación ampliada el efecto lineal aislado pierde significancia estadística directa, manteniéndose firme y robusto el término cuadrático ($-0,005$, $p < 0,001$). No obstante, al interactuar la edad con los niveles educativos y el género, se revela que el rendimiento del ciclo vital no es homogéneo, sino que varía significativamente según la formación académica y el sexo del trabajador.
- Dinámicas de género y composición del hogar: En el modelo parsimonioso el coeficiente de varón indicaba una diferencia fija positiva de 4,28 horas semanales. Sin embargo, al incorporar las interacciones (edad:sexo y sexo:menores.6), el efecto principal del género se desvía, cobrando protagonismo los términos cruzados: la interacción entre varón y la presencia de menores de 6 años arroja un impacto positivo y altamente significativo (3,35 $p < 0,001$), lo que contrasta fuertemente con el efecto general negativo que la carga de menores ejerce sobre el total de la población.
- Retornos educativos y selectividad: Las categorías del nivel educativo profundizan su castigo en términos de horas trabajadas en los tramos medios y altos (niveles 3 a 6), mostrando coeficientes negativos más pronunciados y estadísticamente sólidos. Además, las interacciones de la edad con los niveles educativos (especialmente de los niveles 3 al 6) resultan significativas, sugiriendo que la trayectoria laboral y la cantidad de horas ofertadas evolucionan de manera dispar a lo largo de la vida según el grado de instrucción formal alcanzado.
- Ocupaciones y ramas de actividad: El control exhaustivo por rama e inserción ocupacional mantiene la fuerte penalización horaria en sectores específicos como la enseñanza (rama P) y el servicio doméstico (rama T), con caídas que superan las 14 horas semanales respecto a la categoría de referencia. A su vez, ramas como la industria manufacturera o ciertos servicios, que en el modelo simple mostraban coeficientes aislados, ajustan su dispersión al interactuar con el set ampliado de controles geográficos (aglomerados).

Para evaluar si la incorporación de una mayor complejidad estructural optimiza la especificación sin incurrir en ineficiencias, se contrastó el modelo OLS parsimonioso frente a la especificación ampliada. En primer término, el análisis de la bondad de ajuste muestra que el R^2 ajustado experimenta una mejora moderada al pasar de 0,250 a 0,269. Esta ganancia encuentra respaldo en el Criterio de Información de Akaike (AIC), el cual registra una disminución sustancial desde 101100,4 en el modelo base hasta 100857,0 en el modelo largo. Dicha reducción confirma que el incremento en la verosimilitud compensa la penalización por la adición de parámetros, validando estadísticamente la inclusión de la nueva estructura de variables.

Por su parte, la evaluación de la multicolinealidad mediante los Factores de Inflación de la Varianza Generalizados indica que las nuevas dimensiones operan en niveles estables y sin indicios de una inflación de varianza severa, con excepción de la estructura etaria que se mantiene en rangos moderados. Esto demuestra que los regresores incorporados no saturan matemáticamente la matriz de diseño.

No obstante la estabilidad observada y con el propósito de contrastar la robustez de las estimaciones frente al riesgo de sobreajuste propio de la alta dimensionalidad, el análisis se complementa mediante la implementación de técnicas de regularización (Ridge y Lasso).

Para evaluar la capacidad predictiva fuera de muestra de la especificación extendida, se replicó el mismo procedimiento de validación cruzada y partición de datos (80 % entrenamiento / 20 % prueba) utilizado en el modelo base. Al igual que en la especificación previa, los resultados muestran un 'empate técnico' entre las tres alternativas. El estimador de mínimos cuadrados ordinarios alcanzó el mejor rendimiento predictivo con un MSE de 142,08, seguido muy de cerca por Lasso (142,23), el cual logra un desempeño prácticamente idéntico gracias a su capacidad de selección de variables (en este caso anuló las categorías nivel educativo 2, 3 y 7). Por último, Ridge se ubica en 142,77, confirmando que las técnicas de regularización preservan la estabilidad del modelo extendido sin penalizar excesivamente la capacidad de generalización fuera de muestra.

Asimismo, estas similitudes en el desempeño predictivo también se reflejan claramente en el gráfico de valores observados versus predichos. Al igual que en la especificación parsimoniosa, la dispersión y la alineación de las nubes de puntos de los tres estimadores muestran un comportamiento visual prácticamente idéntico. Esto evidencia que, incluso al incorporar un conjunto más amplio de variables e interacciones, la estructura de las predicciones se mantiene sumamente estable entre los diferentes métodos de regularización.




Figura 14

5. Conclusiones

El presente trabajo se propuso responder como pregunta central de investigación: ¿De qué manera los factores sociodemográficos y las características del puesto de trabajo determinan la cantidad de horas trabajadas por los asalariados en Argentina, y cuáles de estas variables emergen como los predictores más relevantes bajo un esquema de selección por regularización? A partir de la explotación de los microdatos de la EPH (primer trimestre de 2026) y la aplicación combinada de MCO y métodos de regularización (Ridge y Lasso), es posible extraer conclusiones tanto metodológicas como económicas considerables.

En primer término, respecto a la síntesis de los hallazgos principales, se confirmó la hipótesis de la U invertida a través de la edad y su término cuadrático, lo que evidencia que la intensidad de la oferta laboral crece en las etapas iniciales y medias de la vida activa para luego descender hacia la edad de retiro. Asimismo, se constató que los varones destinan en promedio un volumen significativamente mayor de horas semanales al mercado laboral en comparación con las mujeres, una asimetría que se complejiza al incorporar interacciones con la estructura del hogar. Por su parte, la implementación de Ridge y Lasso demostró que, frente a un conjunto de variables explicativas acotado y bien estructurado, los modelos penalizados alcanzan un desempeño predictivo fuera de muestra muy similar al de MCO, reflejándose en empates técnicos en el MSE de prueba. No obstante, Lasso cumplió con éxito su rol de selección de características al anular aquellas categorías de baja importancia.

Durante el proceso de estimación, sin embargo, surgieron ciertos resultados que se apartaron de las predicciones teóricas tradicionales. Por un lado, en cuanto al impacto positivo de la presencia de menores de 6 años, mientras que la teoría económica estándar de la oferta laboral familiar suele postular que la presencia de niños pequeños en el hogar genera restricciones temporales que reducen la cantidad de horas ofrecidas en el mercado laboral formal, el coeficiente positivo encontrado en el modelo base y la fuerte interacción positiva con los varones sugieren el predominio de un efecto presión de ingresos. En el contexto del mercado laboral asalariado argentino, los hogares con niños pequeños enfrentan mayores necesidades financieras lo que obliga a los perceptores de ingresos a intensificar su participación laboral y extender sus jornadas para evitar la caída del bienestar del hogar.

Por otro lado, se observó un signo negativo en los niveles educativos superiores. Bajo el enfoque tradicional, un mayor nivel educativo incrementa el salario por hora, lo que encarece el tiempo libre por efecto sustitución y estimula una mayor oferta de horas. La predominancia de coeficientes negativos en los niveles educativos altos y universitarios respecto al nivel de referencia apunta, en cambio, a un efecto renta dominante sumado a las características de la estructura del empleo formal calificado. Los individuos con mayor educación suelen acceder a puestos con mayores salarios relativos, permitiéndoles alcanzar el nivel de ingresos deseado trabajando una menor cantidad de horas, lo que se traduce en una mayor preferencia por el ocio o por empleos altamente productivos pero de menor intensidad horaria, tales como cargos profesionales o docentes específicos. Del mismo modo, esto puede reflejar la penalización horaria o la rigidez a la baja de ciertas ocupaciones profesionales altamente reguladas o empleos públicos especializados.

Finalmente, la equivalencia predictiva entre MCO y los métodos de penalización —que inicialmente era lo contrario a la expectativa de que la regularización superara holgadamente a MCO debido al riesgo de sobreajuste por alta dimensionalidad— se explica porque la multicolinealidad en el conjunto de datos final no resultó tan severa como para degradar la varianza de los estimadores clásicos de forma crítica. Al no existir una masa de variables irrelevantes o colineales que distorsionen la matriz de diseño, MCO mantiene sus propiedades de eficiencia asintótica, lo que valida que los métodos de regularización actúan en este contexto principalmente como herramientas de control de estabilidad.

En definitiva, el análisis demuestra que la oferta laboral asalariada en Argentina responde de manera compleja a incentivos económicos, restricciones demográficas y segmentaciones sectoriales, donde las características intrínsecas del mercado de trabajo local desafían en distintos aspectos a las predicciones de los modelos microeconómicos tradicionales.